H A R M O N I A V I S I O N

Product Requirements Document

Privacy-Preserving Federated Learning System
for Breast Cancer Mass Segmentation

Benchmark: Federated Learning vs. Centralized Training

Versiyon:	1.0
Versiyon:	1.0
Tarih:	Nisan 2026
Durum:	Taslak

1. Genel Bakış

1.1 Proje Tanımı

Bu proje, meme kanseri kitle (mass) segmentasyonu için gizlilik odaklı bir Federated Learning (FL) sistemi geliştirmeyi hedeflemektedir. Sistem, farklı hastaneleri simüle eden dağıtık düğümler üzerinde U-Net tabanlı bir segmentasyon modelini eğiterek, ham hasta verilerini paylaşmadan yüksek performanslı bir global model üretmeyi amaçlamaktadır.

Projenin ana çıktısı, Federated Learning ile eğitilen modelin merkezi (centralized) eğitim ile elde edilen modele karşı kapsamlı bir benchmark karşılaştırmasıdır.

1.2 Problem Tanımı

- Sağlık verilerinin gizliliği (KVKK/GDPR) nedeniyle hastaneler arası veri paylaşımı mümkün değildir.
- Tek merkezde eğitilen modeller, farklı cihaz ve protokollerden gelen görüntülerde genelleme yapamaz (domain shift).
- Merkezi veri toplama, güvenlik riski ve yasal engeller barındırır.

1.3 Çözüm Yaklaşımı

Federated Learning ile hastanelerdeki veriler yerelde kalır; sadece model ağırlıkları merkezi sunucuya iletilir. FedAvg algoritması ile bu ağırlıklar birleştirilerek global model güncellenir. Böylece veri gizliliği korunurken, çoklu veri kaynağından beslenen güçlü bir model elde edilir.

2. Altyapı ve Ortam

2.1 Sunucu Mimarisi

Sistem, DigitalOcean üzerinde 3 adet VPS (Virtual Private Server) ile Hub-and-Spoke topolojisinde kurulacaktır:

Sunucu	Rol	Önerilen Spec
VPS-1 (Server)	Merkezi FL sunucusu. Flower server çalıştırır, FedAvg ile ağırlık birleştirme yapar.	4 vCPU, 8 GB RAM, 80 GB SSD
VPS-2 (Hastane A)	Birinci hastane simülasyonu. Yerel veri seti üzerinde U-Net eğitimi yapar, güncellenmiş ağırlıkları sunucuya gönderir.	4 vCPU, 8 GB RAM, 80 GB SSD

VPS-3 (Hastane B)	Ikinci hastane simülasyonu. Aynı süreç farklı veri bölümü ile.	4 vCPU, 8 GB RAM, 80 GB SSD

2.2 VPS Güvenlik Konfigürasyonu

Tüm VPS'ler aşağıdaki güvenlik önlemleri ile korunacaktır:

2.2.1 Ağ Güvenliği

- SSH anahtar tabanlı kimlik doğrulama (parola ile giriş devre dışı)
- SSH portu varsayılandan değiştirilecek
- UFW (Uncomplicated Firewall) ile sadece gerekli portlar açılacak
- Sunucular arası iletişim WireGuard VPN tüneli üzerinden gerçekleşecek
- Flower serverın dinlediği port, sadece VPN subnet'inden erişilebilir olacak
- Fail2Ban ile brute-force saldırılarına karşı koruma

2.2.2 İletişim Güvenliği

- Tüm Flower gRPC trafiği TLS 1.3 ile şifrelenecek
- Self-signed veya Let's Encrypt sertifikaları kullanılacak
- Sunucu-istemci arasında karşılıklı TLS (mTLS) doğrulaması yapılacak

2.2.3 Sistem Sertleştirme

- Gereksiz servisler devre dışı bırakılacak
- Otomatik güvenlik güncellemeleri (unattended-upgrades) etkinleştirilecek
- Root ile doğrudan SSH erişimi kapatılacak
- Docker container'ları non-root kullanıcı ile çalıştırılacak

---

3. Veri Toplama ve Hazırlık

3.1 Veri Seti

Kaynak: CBIS-DDSM (Curated Breast Imaging Subset of Digital Database for Screening Mammography)

Tür: Dijital mamogram görüntüleri

Alt Küme: Sadece mass (kitle) vakaları

Format: DICOM görüntüleri + ROI segmentasyon maskeleri

3.2 Veri Önişleme Pipeline'ı

Aşağıdaki adımlar sırasıyla uygulanacaktır:

#	Adım	Detay
1	DICOM Dönüştürme	DICOM dosyaları PNG/NumPy array formatına dönüştürülecek. Piksel değerleri DICOM metadata'sındaki window/level bilgisine göre normalize edilecek.
2	Boyut Standardizasyonu	Tüm görüntüler 256×256 piksel boyutuna yeniden boyutlandırılacak. Maskeler aynı boyutlandırma ile nearest-neighbor interpolasyon kullanılarak ölçeklenecek.
3	Piksel Normalizasyonu	Piksel yoğunlukları [0, 1] aralığına normalize edilecek (min-max normalizasyon).
4	Veri Artırma	Eğitim setine rastgele döndürme (±15°), yatay çevirme (horizontal flip), elastik deformasyon ve parlaklık/kontrast ayarlama uygulanacak.
5	Train/Val/Test Bölümleme	Veri seti %70 eğitim, %15 doğrulama, %15 test olarak bölünecek. Bölümleme hasta bazında yapılacak (aynı hastanın görüntüleri aynı sette kalacak).

3.3 Hastane Simülasyonu için Veri Dağılımı

Benchmark'ın iki farklı senaryo altında gerçekleştirilmesi planlanmıştır:

Senaryo 1: IID (Homojen Dağılım)

- Eğitim verisi 2 hastaneye eşit olarak bölünür (%50 – %50).
- Her iki hastanede benign/malignant dağılımı yaklaşık eşittir.
- Bu senaryo, ideal koşullarda FL performansını ölçer.

Senaryo 2: Non-IID (Heterojen Dağılım)

- Eğitim verisi bilerek dengesiz dağıtılır.
- Örnek: Hastane A ağırlıklı olarak benign vakaları, Hastane B ağırlıklı olarak malignant vakaları alır.
- Bu senaryo, gerçek dünya heterojenliğini simüle eder ve FL'nin Non-IID verideki performansını test eder.

Her iki senaryoda da test seti aynı kalır ve tüm modeller aynı test setinde değerlendirilir.

4. Model Mimarisi (U-Net)

4.1 Mimari Yapı

Segmentasyon motoru olarak standart U-Net mimarisi kullanılacaktır. Mimari, encoder-bottleneck-decoder yapısından oluşur ve skip connection'lar ile uzamsal detay koruması sağlar.

Katman	Yapı	İşlev
Encoder (4 blok)	2× Conv 3×3 + BatchNorm + ReLU + MaxPool 2×2	Hiyerarşik öznitelik çıkarma, uzamsal boyut azaltma
Bottleneck	2× Conv 3×3 + BatchNorm + ReLU	En yüksek seviye semantik temsil
Decoder (4 blok)	TransposedConv 2×2 + Skip Connection + 2× Conv 3×3	Uzamsal çözünürlük kurtarma, hassas lokalizasyon
Output	Conv 1×1 + Sigmoid	Binary maske üretimi (0: arka plan, 1: kitle)

4.2 Kayıp Fonksiyonu

Sınıf dengesizliğini ele almak için hibrit kayıp fonksiyonu kullanılacaktır:

L_total = L_BCE + L_Dice

- Binary Cross-Entropy (BCE): Global piksel sınıflandırma doğruluğu için
- Dice Loss: Tümör şekil örtüşme optimizasyonu için (özellikle küçük kitlelerde etkili)

4.3 Eğitim Hiperparametreleri

Parametre	Değer
Optimizer	Adam (lr=1e-4)
Batch Size	16 (VPS bellek kapasitesine göre ayarlanabilir)
Early Stopping	Patience: 10 epoch (validation loss'a göre)
Input Boyutu	256 × 256 × 1 (grayscale)
Framework	PyTorch

5. Federated Learning Sistemi

5.1 Framework

Seçilen Framework: Flower (flwr)

Flower, PyTorch ile native uyumlu, üretim kalitesinde bir FL framework'üdür. gRPC tabanlı iletişim altyapısı sağlar ve özel strateji tanımlamaya olanak verir.

5.2 FedAvg Protokolü

Eğitim döngüsü aşağıdaki adımlarla gerçekleşir:

#	Adım	Açıklama
1	Broadcast	Server mevcut global modeli tüm client'lara gönderir.
2	Yerel Eğitim	Her client, aldığı modeli kendi özel veri seti üzerinde E epoch boyunca eğitir.
3	Upload	Client'lar güncellenmiş model ağırlıklarını VPN üzerinden server'a gönderir.
4	Aggregation	Server, FedAvg ile ağırlıklı ortalama hesaplar: $W_new = \sum(n_k/n) \times W_k$
5	Dağıtım	Yeni global model client'lara geri gönderilir.
6	Convergence	Adımlar 1–5, global model performansı stabilize olana kadar tekrarlanır.

5.3 FL Hiperparametreleri

Parametre	Değer
Client Sayısı	2 (Hastane A + Hastane B)
Yerel Epoch (E)	5 (round başına, ayarlanabilir)
Round Sayısı	Convergence'a kadar (sabit sayı değil)
Convergence Kriteri	Validation DSC'de ardışık 10 round boyunca anlamlı iyileşme olmaması
Aggregation	FedAvg (veri büyüklüğüne göre ağırlıklı)
Min Fit Clients	2 (tüm client'lar her round'a katılır)

5.4 Model Ağırlık Güvenliği: Partial Homomorphic Encryption (PHE)

FL sürecinde client’lardan server’a iletilen model ağırlıklarına ek bir gizlilik katmanı eklemek için kısmi homomorfik şifreleme (PHE) uygulanacaktır.

Neden Tam Homomorfik Değil?

- Tam Homomorfik Şifreleme (FHE) hesaplama maliyeti çok yüksektir ve model ağırlıkları üzerinde pratik değildir.
- PHE (orn. Paillier), toplama işlemi üzerinde homomorfik özellik sağlar; bu FedAvg için yeterlidir çünkü aggregation temelde ağırlıklı toplamadır.

Uygulama Yaklaşımı

- Kütüphane: TenSEAL veya PySyft (CKKS şeması da değerlendirilebilir)
- Client'lar model ağırlıklarını şifreleyerek server'a gönderir
- Server, şifreli ağırlıklar üzerinde aggregation yapar
- Sonuç, client'lara geri gönderilmeden önce deşifrelenir
- Benchmark'ta PHE'nin eklediği computation overhead ve iletişim maliyeti de ölçülecektir

---

6. Merkezi Eğitim (Baseline)

FL benchmark'ı için bir referans noktası oluşturmak üzere, aynı U-Net modeli tüm eğitim verisi tek bir makinede toplanarak merkezi olarak eğitilecektir.

6.1 Merkezi Eğitim Koşulları

- Aynı model mimarisi (U-Net)
- Aynı hiperparametreler (optimizer, learning rate, loss fonksiyonu)
- Aynı veri önişleme pipeline'ı
- Aynı train/val/test bölümleme
- Eğitim, convergence'a kadar (early stopping ile)
- Tüm eğitim verisi tek VPS üzerinde birleştirilmiş olarak kullanılır

Bu koşullar, FL ve merkezi eğitim arasındaki farkın sadece eğitim yönteminden kaynaklanmasını garanti eder.

---

7. Benchmark ve Değerlendirme

7.1 Değerlendirme Metrikleri

Model Performans Metrikleri

Metrik	Açıklama
Binary Accuracy	Piksel bazında doğru sınıflandırma oranı
Dice Similarity Coefficient (DSC)	Tahmin edilen maske ile ground truth arasındaki örtüşme. Ana performans metriği.
IoU (Intersection over Union)	Kesişim / birleşim oranı. Segmentasyon kalitesinin doğrulanması.
Precision & Recall	False positive ve false negative analizi için.

Sistem Performans Metrikleri

Metrik	Açıklama
Communication Cost	Round başına transfer edilen toplam veri boyutu (MB). PHE ile ve PHE olmadan ayrı ölçülecek.
Training Time	Toplam eğitim süresi (convergence'a kadar). FL vs. merkezi karşılaştırma.
Round Başına Süre	Tek bir FL round'ının ortalama süresi (yerel eğitim + iletişim + aggregation).
Convergence Hızı	Hedef DSC değerine ulaşmak için gereken round/epoch sayısı.
PHE Overhead	Şifreleme/deşifreleme işlemlerinin eklediği ek süre ve hesaplama maliyeti.

7.2 Benchmark Matrisi

Aşağıdaki tablo, karşılaştırılacak tüm konfigurasyonları özetlemektedir:

#	Konfigürasyon	Veri Dağılımı	PHE	Eğitim Tipi
C1	Merkezi Baseline	Tüm veri tek merkezde	Yok	Centralized
F1	FL + IID	50/50 homojen	Yok	Federated
F2	FL + IID + PHE	50/50 homojen	Var	Federated
F3	FL + Non-IID	Heterojen	Yok	Federated
F4	FL + Non-IID + PHE	Heterojen	Var	Federated

7.3 Beklenen Çıktılar

- Tüm konfigurasyonlar için DSC, IoU, Accuracy değerleri tablo ve grafik olarak sunulacak
- FL vs. Merkezi performans farkı yüzdelik olarak raporlanacak (literatürde %2–3 fark beklenir)
- IID vs. Non-IID senaryolarındaki performans düşüşü analiz edilecek
- Communication cost ve training time grafikleri çıkarılacak
- PHE'nin eklediği overhead ayrıca raporlanacak
- Convergence eğrileri (DSC vs. round/epoch) tüm konfigurasyonlar için çizilecek

8. Teknoloji Stack

Katman	Teknoloji	Açıklama
Derin Öğrenme	PyTorch	U-Net implementasyonu, eğitim ve inference
Federated Learning	Flower (flwr)	FL server/client, FedAvg stratejisi, gRPC iletişim
Homomorfik Şifreleme	TenSEAL / PySyft	PHE ile model ağırlık şifreleme
Veri İşleme	NumPy, Pillow, pydicom	DICOM dönüştürme, önişleme, augmentation
Veri Artırma	Albumentations	Eğitim setine augmentation uygulama
VPN	WireGuard	VPS'ler arası güvenli tünel
Altyapı	DigitalOcean VPS	3× VPS: 1 server + 2 client
Konteynerizasyon	Docker	Ortam izolasyonu ve tekrarlanabilirlik
Versiyon Kontrol	Git / GitHub	Kod yönetimi ve işbirliği
Raporlama	Matplotlib, Seaborn	Benchmark grafikleri ve görselleştirme

9. Proje Çıktıları

Projenin tamamlanması sonucunda aşağıdaki çıktılar üretilecektir:

#	Çıktı	Açıklama
1	Benchmark Raporu	Tüm konfigurasyonlar için performans metrikleri, grafikler ve analiz. FL vs. Centralized detaylı karşılaştırma.
2	Eğitilmiş Modeller	5 farklı konfigurasyonda eğitilmiş U-Net model ağırlıkları (.pt dosyaları).
3	Kaynak Kod	Tüm pipeline'ı içeren GitHub repository: veri önişleme, model, FL client/server, benchmark scriptleri.
4	Altyapı Dokümantasyonu	VPS kurulum rehberi, güvenlik konfigurasyonu, WireGuard setup, Docker compose dosyaları.
5	Veri Hazırlık Scriptleri	CBIS-DDSM indirme, DICOM dönüştürme, IID/Non-IID bölümleme scriptleri.

10. Başarı Kriterleri

Kriter	Hedef
Merkezi Model DSC	≥ 0.80
FL (IID) DSC	Merkezi modelin DSC değerinin en fazla %5 altında
FL (Non-IID) DSC	Merkezi modelin DSC değerinin en fazla %10 altında
Veri Gizliliği	Hiçbir ham hasta verisi VPS dışına çıkmayacak
PHE Entegrasyonu	Model ağırlıkları şifreli olarak iletilebilecek
Altyapı Güvenliği	Tüm VPS'ler arası iletişim WireGuard + TLS üzerinden
Tekrarlanabilirlik	Tüm deneyler seed ile tekrarlanabilir olacak

11. Kısıtlar ve Riskler

11.1 Bilinen Kısıtlar

- VPS kaynak limitleri nedeniyle batch size ve model büyüklüğü kısıtlı olabilir.
- Sadece 2 client ile simülasyon yapıldığı için gerçek dünya heterojenliği tam olarak yansıtılamayabilir.
- CBIS-DDSM açık bir veri setidir; gerçek hastane verisinin çeşitliliğini tam olarak temsil etmez.
- PHE, hesaplama maliyetini artıracağından eğitim süresi uzayabilir.

11.2 Riskler ve Önlemler

Risk	Önlem
VPS belleğinin model eğitimi için yetersiz kalması	Batch size küçültülecek, gradient accumulation uygulanacak. Gerekirse VPS spec yükseltilecek.
Non-IID senaryoda FL convergence zorluğu	Yerel epoch sayısı ve learning rate ayarlanacak. Gerekirse FedProx gibi alternatif strateji denenecek.
VPS'ler arası ağ gecikmesi	WireGuard hafif bir VPN'dir, gecikme minimal olacaktır. Round süresi metriklerde izlenecek.
PHE entegrasyonunda performans düşüşü	PHE'siz ve PHE'li sonular ayrı raporlanacak. PHE kabul edilemez overhead getirirse CKKS'e geçiş değerlendirilecek.

CBIS-DDSM veri kalitesi sorunları	Veri önişleme aşamasında bozuk veya eksik maskeler filtrelenecek. EDA (Exploratory Data Analysis) öncelikli yapılacak.

12. Tanım ve Kısaltmalar

Kısaltma	Açıklama
FL	Federated Learning — Dağıtık makine öğrenimi yöntemi
FedAvg	Federated Averaging — Model ağırlıklarının ağırlıklı ortalaması ile birleştirilmesi
PHE	Partial Homomorphic Encryption — Kısmi homomorfik şifreleme
DSC	Dice Similarity Coefficient — Segmentasyon örtüşme metriği
IoU	Intersection over Union — Kesişim/birleşim oranı
BCE	Binary Cross-Entropy — İkili çapraz entropi kayıp fonksiyonu
IID	Independent and Identically Distributed — Homojen veri dağılımı
Non-IID	Heterojen veri dağılımı
CBIS-DDSM	Curated Breast Imaging Subset of Digital Database for Screening Mammography
VPS	Virtual Private Server
mTLS	Mutual TLS — Karşılıklı TLS kimlik doğrulaması
KVKK	Kişisel Verilerin Korunması Kanunu